

**UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
CÂMPUS CURITIBA**

**MATHEUS IZIDORO DE ALMEIDA
RUY HINSCHING
THOMAZ SUZUKI**

PROJETO CONDUTOR

**CURITIBA
2021**

1 CENÁRIOS

1.1 DISTRIBUIÇÃO DE VACINAS

Esse cenário consiste em estabelecer a “melhor” rota para a distribuição das vacinas com base nas seguintes informações:

Os carregamentos de vacina que chegam à Curitiba ficam armazenados em um depósito refrigerado na rodoviária. As vacinas devem ser transportadas em uma só viagem para todas as Unidades de Saúde da tabela 1 e o motorista deve fazer o circuito retornando à rodoviária de forma mais rápida possível. Cada nova entrega deve ser planejada porque os tempos de viagens entre as unidades de saúde variam em função do tráfego de veículos.

UNIDADE DE SAÚDE	ENDEREÇO
São João Del Rey	Rua Realeza 259
Waldemar Monastier	Rua Romeu Bach 80
Bacacheri	Avenida Erasto Gaertner 797
Cajuru	Rua Pedro Bochino 750
São Miguel	Rua Des. Cid Campelo 8060
Mãe Curitiba	Rua Jaime Reis 331
Fanny Lindóia	Rua Conde dos Arcos 295
Santa Quitéria 1	Rua Divina Providência 1445
Bom Pastor	Rua José Casagrande 220
Santa Rita	R. Adriana Ceres Zago Bueno 1350

Tabela 1: Unidades de Saúde de Curitiba

1.2 O CARREGADOR DE VACINAS

O carregador (que acompanha o motorista) ao chegar em uma unidade de saúde deve deixar as caixas térmicas de vacina no local onde se encontra a geladeira de armazenamento transportando uma caixa por vez nos braços.

O carregador tem um mapa de cada US. Como as caixas são volumosas e as vacinas frágeis, ele prefere o caminho mais curto do ponto de chegada até onde deve buscar/deixar os pacotes. Ocorre que uma (ou mais) partes do caminho mais curto podem estar obstruídas (e.g. limpeza de um corredor, elevador desligado, obstrução). Neste caso, ele recalcula o caminho.

As geladeiras para armazenamento das vacinas possuem uma organização padronizada. No cenário utilizado, são geladeiras domésticas. É função da pessoa responsável pelo estoque de vacinas armazenar os pacotes corretamente (consultar seção 2.4.1 Manual da Rede de Frio do Ministério da Saúde, páginas 16 e 17).

2. METODOLOGIA

Dado o nível de complexidade do problema resolvemos dividi-lo em 2 etapas. A etapa 1 é a definição do caminho que o motorista deverá realizar para fazer as entregas da maneira mais rápida possível, conforme os métodos estipulados pelos responsáveis pela distribuição de vacinas, respeitando os critérios de prioridade estipulados. A etapa 2 é a definição do trajeto a ser percorrido pelo carregador até a geladeira de armazenamento da unidade de saúde.

Nosso objetivo é maximizar a eficiência na entrega das informações pertinentes à situação em relação a pandemia de cada unidade de saúde, de forma a possibilitar aos responsáveis pela logística e planejamento de distribuição de vacinas, à tomarem decisões bem fundamentadas em dados com estimativas próximas a realidade.

Resolução da Etapa 1:

A etapa 1 será dividida em duas fases. A primeira fase é o fornecimento das informações referentes à análise e estimativa das variáveis referentes a propagação do vírus em cada unidade de saúde para a semana, de forma que os responsáveis pelo

planejamento e distribuição das vacinas possam pensar no melhor método possível para distribuir as vacinas de maneira eficiente. A segunda fase é a definição do caminho que o motorista deverá realizar para fazer as entregas da maneira mais rápida possível, respeitando os critérios de prioridade estipulados.

2.1 DISTRIBUIÇÃO DE VACINAS

- Agente
 - Único: Apenas o software calcula a rota a ser seguida
 - Baseado em objetivos: Entrega em menor tempo, entrega em lugares mais necessitados.
- Ambiente
 - Estocástico: Imprevisibilidade no trânsito e em possíveis problemas na rota.
 - Sequencial: O entregador tem que saber em quais Unidades de Saúde ele já entregou, para não visitar duas vezes a mesma Unidade de Saúde e deixar de visitar outra.
 - Contínuo: Devido a grandezas contínuas envolvidas no cálculo da rota (distância, tempo).

2.1.1 ANÁLISE E ESTIMATIVA DAS VARIÁVEIS REFERENTES A PROPAGAÇÃO DO VÍRUS EM CADA UNIDADE DE SAÚDE

Com o auxílio de uma rede neural híbrida com algoritmos genéticos, os responsáveis pela distribuição e designação das vacinas poderão avaliar qual o melhor método para se utilizar frente a realidade momentânea da situação local referente ao vírus e suas estimativas esboçadas pelo algoritmo.

O algoritmo utilizará os parâmetros referentes à pandemia do coronavírus, são eles: Número de contaminações, número de mortes, número de infectados, número de recuperados, número de pessoas pertencentes a região da unidade de saúde e a porcentagem da quantidade de leitos de enfermaria e UTIs utilizados. Todos estes parâmetros serão referentes ao intervalo de 1 semana, de domingo à sábado, para que os erros referentes às variáveis de contagem devido ao dia da semana possam ser minimizados.

A rede neural artificial a princípio terá 3 camadas neurais, sendo possível alterar isso posteriormente para uma melhor adequação ao problema se necessário, com cada camada possuindo 7 neurônios e cada neurônio irá possuir 7 pesos pelo fato de haverem 7 variáveis de entrada. Os valores colocados na entrada são a soma dos valores diários em uma semana concernentes a cada variável. A função de ativação será do tipo sigmóide, para uma transição mais suave e adequação mais precisa dos parâmetros. Os valores de saída serão as estimativas dos números de cada variável, para a próxima semana.

Toda vez que uma semana se passar e os novos dados forem coletados, o algoritmo irá comparar as estimativas realizadas por cada indivíduo ou cromossomo, que é uma rede neural, para avaliar através de uma função de *fitness* quais os indivíduos chegaram mais próximos dos dados reais coletados.

Após a verificação dos 10 indivíduos mais adequados, às redes neurais que foram selecionadas como as mais adequadas realizaram o algoritmo de *backtracking*, com uma taxa de aprendizagem de 0,05, para melhor se adequarem aos dados reais e então será realizado o processo de recombinação, ou *crossover*, que constitui-se de uma recombinação aleatória dos pesos dos indivíduos, cada camada neural será recombinada aleatoriamente formando uma nova população de 100 indivíduos, após esta recombinação randômica será realizado o processo de mutação que irá, para cada novo indivíduo, selecionar um peso aleatoriamente em um neurônio aleatório em cada camada neural e irá modificá-lo randomicamente com um aumento ou decréscimo de até 50% no valor deste peso.

Este processo será repetido até que a convergência atinja 95% em comparação com os dados reais coletados.

As possibilidades de má interpretação dos dados ou má utilização existem, pode ser que as pessoas responsáveis por analisar estes dados façam uma análise com pouca reflexão e acabem realizando uma distribuição não eficiente de vacinas, ou então a análise e as reflexões sobre os dados possam ser criteriosas e corretas permitindo alcançar um bom índice de distribuição de vacinas de forma que otimize a minimização de casos de covid-19, por isso se faz necessário um uso cauteloso das estimativas propostas.

A apresentação das estimativas destes dados será sempre associada à convergência atingida na última semana calculada, para que a pessoa que for analisar os dados possa ter uma estimativa melhor da confiabilidade do algoritmo.

Segue abaixo as variáveis utilizadas e enumeradas.

1. Número de contaminações. [N_cont]
2. Número de mortes. [N_mort]
3. Número de infectados. [N_infec]
4. Número de recuperados. [N_recup]
5. Número de pessoas pertencentes a região da unidade de saúde [N_pessUS]
6. Porcentagem da quantidade de leitos de enfermaria utilizados. [P_lei_enf]
7. Porcentagem da quantidade de leitos de UTIs utilizados. [P_lei_uti]

Função de adequabilidade ou *Fitness* utilizada no algoritmo será a comparação do resultado obtido para a projeção de uma variável em comparação com o valor real obtido do meio analisado. Por isso serão realizadas 7 comparações, uma para cada variável e será feito uma soma da porcentagem dos erros quadráticos de cada variável para se obter uma média quadrática da porcentagem dos erros para cada indivíduo da população para uma posterior análise dos indivíduos mais adequados. O indivíduo mais adequado será aquele que possuir o menor erro percentual somado.

2.1.2 OTIMIZAÇÃO DO TRAJETO

Na fase 2 ocorre a obtenção do trajeto ótimo considerando quantas caixas cada U.S. irá receber de forma a otimizar os resultados da imunização da população para a minimização dos casos graves e mortes por COVID-19.

O problema será representado como um grafo, onde cada nó representa uma Unidade de Saúde. Considerando como atributos de cada nó o endereço da U.S., seu nome e o número de caixas que a respectiva U.S. deve receber. E como atributos das arestas, a distância entre cada U.S. em quilômetros, a velocidade máxima permitida na via e a qualidade do tráfego na via.

Para resolver esse problema decidimos usar algoritmo genético, tendo em vista a possibilidade de escalabilidade (diversos entregadores, aumento no número de U.S.).

O algoritmo é executado antes do entregador sair da rodoviária, informando a ele um vetor com a rota que o entregador deve seguir. Quando o entregador chega em uma U.S., o nó referente a ela recebe um indicativo de visita e o algoritmo checa a próxima entrega a fim de detectar algum possível problema com a mesma. Se nenhum problema for detectado o entregador continua com o caminho pré-estabelecido. Se tiver um problema na rota, o algoritmo é executado novamente, excluindo as U.S. já visitadas, e informa ao motorista a nova rota de entrega.

Após todas as entregas feitas, o algoritmo zera os indicativos de U.S. visitada ou de problema na rota a fim de não causar problemas nas entregas de um próximo dia.

2.1.2 ALGORITMO GENÉTICO

Os Algoritmos Genéticos são capazes de oferecer soluções para problemas do mundo real, tais como problemas de busca e otimização. Embora eles não garantam uma solução ótima, geralmente atingem uma boa aproximação.

- Cromossomo: Vetor em que cada integrante representa uma U.S. e a ordem no vetor representa a ordem em que devem ser visitadas. Esse vetor é um candidato à solução do problema.

- Gene: Um elemento do vetor que representa o cromossomo. No nosso caso representa a U.S a ser visitada.
- Indivíduo: Formado pelo cromossomo e sua aptidão;
- População: Soluções que representam os cromossomos, ou conjunto de indivíduos que evoluem por meio de operadores genéticos.
- Fenótipo: É a manifestação do genótipo no comportamento, fisiologia e morfologia do indivíduo, como um produto de sua interação com o ambiente.
- Genótipo: Estrutura de dados que representa uma solução candidata a um determinado problema.
- Função de avaliação (fitness): A função de avaliação associa a cada indivíduo da população uma medida de aptidão. Ela deve ser escolhida de forma a medir o desempenho de cada indivíduo como solução do problema. No nosso caso ela leva em consideração o tempo total do trajeto entre as U.S e aplica um modificador de tempo baseado na região da U.S caso seja horário de pico.

2.1.3 OPERADORES GENÉTICOS

Os operadores genéticos utilizados são o crossover e a mutação. O objetivo deles é produzir novos cromossomos que possuam propriedades genéticas superiores às encontradas nos pais.

- Crossover: Escolhe-se dois indivíduos pais da população para gerar dois filhos. Primeiro copia-se um trecho de um dos indivíduos pais para um filho e o restante do cromossomo do indivíduo filho é preenchido com as informações do outro indivíduo pai, na mesma sequência para evitar valores repetidos nos genes.
- Mutação Inversiva: Feita através de uma simples troca de posição entre genes de um mesmo cromossomo.

2.1.4 MECANISMOS DE SELEÇÃO

O processo de seleção em um Algoritmo Genético pode ser definido como sendo uma escolha probabilística de cromossomos de uma população tendo como base as suas aptidões, definidas pela função de fitness. Abaixo segue as estratégias utilizadas para a seleção:

- Função Fitness: $fitness(C_i) = \sum_{i=0}^n Distancia(Temp_i, HRdepico_i)$
 - $Temp_i$ é o tempo de deslocamento de uma U.S até a próxima U.S.
 - Horário de pico é descrito como o horário entre 7:00 e 10:00, e o horário entre 17:00 e 20:00.
 - $HRdepico_i$ é a variável de tempo que modifica o tempo previamente previsto para o deslocamento até a próxima U.S baseado no índice da região da U.S de partida atribuído pelo Índice de Tempo de Viagem (ITV 99)*.

*O ITV 99 mensura a média de atraso dos deslocamentos nos períodos de pico, ou seja, o tempo médio perdido pelas pessoas com o tráfego ruim das cidades.

2.2 O CARREGADOR DE VACINAS

Ao chegar em uma unidade de saúde, as caixas devem ser levadas à sala de armazenamento para serem dispostas dentro das geladeiras para conservação das doses de vacinação. O agente será uma aplicação mobile capaz de exibir o mapa e os possíveis caminhos até a sala de armazenamento para o carregador responsável, auxiliando-o em sua escolha de caminho bem como recalculando a trajetória sempre que a existência de um obstáculo seja notificada pelo carregador. Os caminhos serão processados de modo a não interferir nos deslocamentos e ações dos profissionais da unidade de saúde (o carregador portador do smartphone deverá indicar que determinada área está sendo ocupada no

momento) e garantir certo grau de otimalidade ao trajeto, isto é, evitar caminhos de distâncias muito maiores que o caminho ótimo.

2.2.1 AGENTE E AMBIENTE

As características do agente e do ambiente são as seguintes:

- Agente:
 - Único: Não existem agentes diferentes do algoritmo de busca perseguindo objetivos
- Ambiente:
 - Estocástico: O estado do ambiente não depende somente das ações do agente
 - Sequencial: Os estados futuros são dependentes das decisões atuais, isto é, o lugar em que o carregador ocupará dentro de uma U.S em dado momento é resultado das decisões tomadas anteriormente.
 - Dinâmico: O ambiente pode sofrer alterações enquanto o agente delibera sua próxima ação, portanto,este deve estar a todo mundo momento avaliando as mudanças.

2.2.2 REPRESENTAÇÃO DE ESTADO

O agente utilizará o mapa para formular a crença de sua posição dentro da U.S juntamente aos sensores acelerômetro e giroscópio, e o GPS do celular. Os dados extraídos destes sensores serão processados resultando na crença da área em que o carregador se encontra dentro da U.S. Desta forma, uma representação de estado será o nome da área atual do carregador.

Ex: {Recepção}
 {Corredor}
 {Geladeiras}

Como será tratado posteriormente, a estratégia escolhida utiliza o *planning* e a linguagem formal PDDL, sendo assim, um estado pode ser representado na forma: on(Recepção), neighbour(Corredor, Consultório).

2.2.3 : SOLUÇÃO ATRAVÉS DE *PLANNING* E MODELAGEM DE INCERTEZA

Dado que o problema do carregador trata-se da busca de um caminho dentro de um espaço de estados, poderia-se utilizar uma estratégia de busca heurística (informada) com o objetivo de encontrar o caminho ótimo entre o local de chegada do caminhão com as doses até a sala de armazenamento. Uma variação do algoritmo A* com a heurística de distância Euclidiana alcançaria resultados neste objetivo.

Uma questão importante a ser levada em consideração dada a heurística escolhida é que esta não representa situações do mundo tridimensional já que uma US não é um espaço 2D, podendo haver US com 2 andares ou mais. Também, nem sempre será possível se locomover pela unidade pelo mesmo caminho determinado pelo A* devido a portas fechadas, utilização de áreas pelos profissionais da unidade ou demais obstáculos que possam bloquear partes do caminho. A busca informada também pode considerar estados com a informação do andar do agente, por exemplo, entretanto deve-se manter atenção a estes fatores ao gerar o espaço de estados.

Embora possa-se utilizar puramente a busca informada para a resolução do problema de carregamento interno, foi optado utilizar uma estratégia de *planning*, tornando o agente capaz de buscar e encontrar a sequência de ações que resultarão no estado em que o carregador esteja na área de armazenamento. Através do *planning*, o modelador pode inserir uma quantidade de conhecimento que a busca informada pura não seria capaz de utilizar para a resolução do problema. As ações serão replanejadas sempre que o

carregador notifique um obstáculo em determinada área bem como quando o carregador saia do caminho previamente estabelecido.

É necessário modelar as ações, pré-condições e pós-condições após a realização de uma ação considerando o *frame problem*, já que a linguagem formal não tem relação com o domínio do problema, isto é, não é inerente à linguagem conhecer o resultado de uma ação que para o domínio o efeito é claro.

É preciso também levar em conta o grau de certeza em que se pode afirmar que o carregador está em determinada área. Uma afirmação do tipo “o carregador encontra-se no corredor” deve considerar as incertezas com relação aos dados lidos dos sensores e do GPS, portanto uma modelagem do tipo da sentença “o carregador encontra-se no corredor com 70% de certeza” pode funcionar melhor neste caso.

3 : RESULTADOS

As implementações feitas e capturas de telas de execuções de diferentes instâncias dos problemas podem ser encontradas publicamente em https://github.com/mizidoro/csi30_projeto_condutor.

3.1 DISTRIBUIÇÃO DE VACINAS E OTIMIZAÇÃO DE TRAJETO

Com a adição de uma variável fuzzy de modificação da distância baseada na qualidade do tráfego da via a ser utilizada, a função de fitness e o caminho escolhido se tornam mais próximos da realidade, muito diferente do método utilizado na primeira entrega, onde utilizamos uma variável binária que indicava se havia problemas no caminho escolhido ou não.

Foi implementado um algoritmo genético para a resolução do problema do caixeiro viajante, uma instância do problema de entregas.

3.2 ANÁLISE E ESTIMATIVA DAS VARIÁVEIS REFERENTES A PROPAGAÇÃO DO VÍRUS EM CADA UNIDADE DE SAÚDE

Dado a complexidade do problema exposto, utilizar a abordagem de aprendizado de máquinas com um algoritmo de rede neural se mostra a melhor opção visto que as redes neurais podem ser treinadas com padrões muito complexos conforme a profundidade das camadas neurais. Utilizar algoritmos genéticos para auxiliar a rede neural a tentar evitar o problema de overfitting e ajudá-la a achar a melhor estimativa para o problema também se mostraram soluções bem interessantes, pois os algoritmos conseguem se auxiliar, se combinando para realizar a tarefa complexa de calcular uma estimativa, aprendendo com os valores das variáveis passadas para ter uma estimativa com uma pequena margem de erro para que as pessoas possam calcular melhor suas ações frente a esta situação complexa que é a pandemia.

3.3 CARREGADOR DE VACINAS DENTRO DA UNIDADE DE SAÚDE

A API *solver.planning.domains* foi utilizada para a solução dos problemas modelados em PDDL. Com ela foi possível validar a existência de um plano de solução dada a modelagem do domínio e de distintos problemas. As modelagens dos problemas descrevem os diferentes espaços e salas de uma determinada unidade de saúde e os vizinhos destes espaços. Já o domínio contém os predicados do universo de busca da rota de entrega, como por exemplo se determinado espaço está bloqueado, *blocked* (?x), ou se uma sala faz vizinhança com outra, *neighbour* (?x ?y). O predicado do estado inicial de um problema contém a posição do agente no mapa da unidade de saúde, por exemplo, *on*(Recepção). O repositório de implementações contém exemplos de modelagem de 4 distintas unidades de saúde. A resolução do problema pode ser rodada utilizando python, com o comando *py planning.py*.

4. ATIVIDADES DESEMPENHADAS E HORAS DEDICADAS

A equipe se reuniu através da plataforma Discord em ocasiões distintas para discutir o cenário, modelagens e demais aspectos do projeto. Cada reunião durou por volta de 2 horas e contou com todos os membros.

4.1 MATHEUS

Atuou juntamente à equipe nas discussões relacionadas ao desenvolvimento do escopo da modelagem, das limitações e vantagens de cada algoritmo estudado até a primeira entrega para resolver cada subproblema proposto bem como das heurísticas e correlações entre os indicadores sugeridos. O tempo total utilizado nas reuniões foi de 6h.

Também estudou os temas e abordagens fora do horário de reuniões e implementou um algoritmo genético para a resolução do problema do caixeiro viajante - problema de entrega do motorista - a fim de solidificar os conhecimentos ao redor deste algoritmo. O tempo total utilizado foi em torno de 7h.

Para a entrega 2, estudou as vantagens e desvantagens do *planning* para a solução do problema de entrega de doses interno da US e buscou exemplos de implementações de STRIPS em Python para entender aspectos técnicos para a implementação própria da equipe. Também debateu as abordagens dos demais subproblemas com a equipe durante as reuniões. O tempo total de atividades da segunda entrega foi de 8h.

Na entrega 3, se aprofundou na utilização da API *solver.planning.domains* e escreveu a modelagem do domínio do problema de entregas interno em PDDL bem como a modelagem de quatro diferentes cenários de distribuição em US fictícias. Se reuniu com a equipe através de chamadas online para discutir os impactos das diferentes modelagens e atuou em conjunto com a equipe nas correções e revisão do texto final. O tempo total das atividades da terceira entrega foi de 14h.

Total de horas dedicadas: 35h

4.2 RUY

Trabalhou em conjunto com a equipe nas discussões e análises sobre como melhorar e implementar as novas técnicas aprendidas nas últimas aulas, dentre elas as últimas técnicas ensinadas sobre aprendizagem de máquinas e redes neurais, avaliou o projeto de maneira a facilitar a modelagem e a implementação, fez análises relacionadas às limitações de cada método e analisou qual a melhor técnica a ser utilizada para a nova proposta, menos ambiciosa e menos moralmente duvidosa, de somente expor dados de uma estimativa calculada por uma rede neural. Com isso ficará a cargo dos indivíduos responsáveis pela distribuição de vacinas analisar e tomar decisões referentes a como proceder com tais informações.

Total de horas dedicadas: 36h

4.3 THOMAZ

Contribuiu expressivamente para a resolução do problema da rota de entrega das vacinas, focando na modelagem, algoritmo e possíveis subproblemas a serem considerados. Levando em conta também a escalabilidade ligada ao algoritmo utilizado e impacto social de suas escolhas.

Também pesquisou sobre como aplicar a lógica fuzzy para que a função de distância e fitness levassem melhor em conta a qualidade do tráfego na hora da entrega, fazendo com que a escolha do melhor caminho mais se aproxime da realidade.

Implementação do código para a resolução da rota de entrega de vacinas utilizando algoritmos genéticos.

Adição dos modificadores de tempo de viagem baseados nas regiões de partida do trajeto de acordo com o Índice de Tempo de Viagem (ITV99).

Total de horas dedicadas: 34h

5. REFERÊNCIAS BIBLIOGRÁFICAS

- Russel, Stuart. Norvig, Peter. Artificial Intelligence A Modern Approach - Third Edition
- Brachman, Ronald J. Levesque, Hector J. Knowledge Representation and Reasoning. 2004
- Carvalho, Márcia Braga de. Aplicações de meta-heurística genética e fuzzy no sistema de colônia de formigas para problema do caixeiro viajante. Dissertação (Mestrado). Universidade Estadual de Campinas, Faculdade de Engenharia Elétrica e de Computação. 2007
- Descubra os bairros em que motoristas perdem mais tempo no trânsito. Disponível em: <https://medium.com/para-onde-vamos/descubra-os-bairros-em-que-motoristas-perdem-mais-tempo-no-congestionamento-8f5b9f444f6a>. Acessado em 11/05/2021